

Cómo cruzar las tablas de entrega

Guía práctica de los datasets de graduados USTA y sus enlaces


Consultorio de Estadística · Organización *ustadistica* · Periodo 2026-1

Las seis tablas del paquete describen la misma población de graduados vista desde fuentes distintas. Esta guía explica, en lenguaje sencillo, qué contiene cada una, cuál es la llave que las une y cómo combinarlas para responder preguntas, tanto en Excel como en Python.

La idea en una frase. Casi todo se cruza por la **cédula** (columna *identificacion*). Y para la mayoría de las preguntas *no hace falta cruzar nada*: la tabla maestra **06_impacto_consolidado.csv** ya trae, en una sola fila por persona, las tres dimensiones juntas.

1. La llave común: la cédula

Cada graduado se identifica por su número de documento, normalizado a **solo dígitos** (sin puntos, espacios ni guiones) en la columna *identificacion*. Esa columna es la misma en todas las tablas de personas, de modo que unir dos tablas es, simplemente, emparejar las filas que comparten la cédula.



La sexta tabla, **05_cvlac_usta_no_graduados.csv**, es la excepción deliberada: reúne perfiles CvLAC con vínculo USTA que *no* son graduados de la base, así que no comparte cédula con las demás y no se cruza con ellas; es un inventario aparte para futuros enlaces.

2. Qué es cada tabla y a qué nivel está

Antes de cruzar conviene saber la **unidad de cada fila** (el «grano»). Mezclar tablas de grano distinto sin cuidado es la causa más común de cifras infladas.

Tabla	Llave	Una fila por...	Filas
01_graduados_integrado	identificacion	registro de grado (una persona puede tener varios)	197.273
02_proveedores_secop	identificacion	graduado proveedor del Estado	42.889
03_emprendedores_rues	identificacion	graduado con matrícula mercantil	37.544
04_investigadores_cvlac	identificacion / cod_rh	coincidencia graduado–perfil CvLAC	3.403
05_cvlac_usta_no_graduados	cod_rh	perfil CvLAC USTA que <i>no</i> es graduado	3.266
06_impacto_consolidado	identificacion	persona única (todo cruzado)	174.685

Atajo. Si la pregunta es «¿cuántas personas...?» o «¿qué proporción...?», trabaja sobre `06_impacto_consolidado.csv` y filtra columnas. Allí cada persona aparece **una sola vez** con `es_proveedor_secop`, `en_rues`, `en_cvlac`, `n_dimensiones` y `perfil_impacto` ya calculados. Las tablas 02–04 solo se necesitan cuando quieres el *detalle* de una dimensión (la cámara de comercio, el código CIU, la URL del CvLAC, etc.).

3. Cruzar en Excel

1. Abre las dos tablas que quieras unir (por ejemplo, la maestra y `03_emprendedores_rues`).
2. Asegúrate de que `identificacion` esté como **texto** en ambas (ver advertencia abajo).
3. En la tabla destino, agrega una columna y usa **BUSCARV** (o **XLOOKUP**/**BUSCARX** en versiones nuevas):

```
=BUSCARV([@identificacion]; '03_rues'!A:H; 8; FALSO)
```

trae el dato de la columna 8 de la tabla RUES para esa cédula.

4. Para conteos y proporciones, una **tabla dinámica** sobre `06_impacto_consolidado.csv` resuelve casi todo: lleva `sede_principal` a filas y `es_proveedor_secop` a valores (cuenta), y tendrás proveedores por sede sin escribir una sola fórmula.

4. Cruzar en Python (pandas)

Leer y unir por cédula es directo. La clave es forzar `identificacion` a `texto` (`dtype=str`) para que no se pierdan ceros ni se desborde el número.

```
import pandas as pd
KEY = {'identificacion': str}
mae = pd.read_csv("datasets/06_impacto_consolidado.csv", dtype=KEY)
rues = pd.read_csv("datasets/03_emprendedores_rues.csv", dtype=KEY)

# unir la cámara de comercio a la tabla maestra
df = mae.merge(rues[['identificacion', 'camara_comercio', 'giu_principal']],
               on='identificacion', how='left')
```

4.1 Ejemplos resueltos

a) **Personas que son proveedoras del Estado y están matriculadas en el RUES** (sin cruzar nada, sobre la maestra):

```
ambas = mae[mae.es_proveedor_secop & mae.en_rues]
print(len(ambas)) # 11.452 personas
```

b) **Valor total contratado por sede:**

```
mae.groupby("sede_principal").secop_valor_total.sum().sort_values(ascending=False)
```

c) **Cámaras de comercio de los graduados de Arquitectura** (la sede/carrera está en la maestra o en 03; el detalle de cámara, en 03):


```
arq = rues[rues.programa.str.contains('ARQUITECT', case=False, na=False)]
arq.camara_comercio.value_counts().head(10)
```

d) **Perfil multidimensional** (cuántos dejan huella en 1, 2 o 3 fuentes):

```
mae.n_dimensiones.value_counts().sort_index()
```

5. El caso especial de CvLAC

CvLAC no publica la cédula: cada investigador se identifica por un código interno, `cod_rh`. Por eso la tabla `04_investigadores_cvlac` trae *dos* llaves: `identificacion` (para cruzar con el resto de la entrega) y `cod_rh` (para cruzar con las tablas analíticas de investigación, que viven en la carpeta `salidas/`). Ese `cod_rh` es el puente.



Ejemplo: revistas donde publican los investigadores de Derecho.

```

cv = pd.read_csv("datasets/04_investigadores_cvlac.csv", dtype={identificacion:str,cod_rh:str})
issn = pd.read_csv("salidas/cvlac_issn.csv", dtype=str) # cod_rh, issn
oa = pd.read_csv("salidas/cvlac_issn_openalex.csv", dtype=str) # issn, name, country, doaj

der = cv[cv.programa.str.contains("DERECHO", case=False, na=False)]
rev = der.merge(issn, on=cod_rh).merge(oa, on=issn)
rev.name.value_counts().head(10)
  
```

Dos conteos de CvLAC que no hay que confundir. La tabla 04 tiene **3.403** filas (coincidencias nombre–documento) que corresponden a **2.547** personas únicas (cédulas) y a **2.535** perfiles de investigador (`cod_rh`). Para contar *personas* usa `identificacion` con `nunique()`; para contar *perfiles* usa `cod_rh`. La cifra que entra a la maestra y a las tasas del informe es la de personas: **2.547** (el 1,5 %).

6. Tablas analíticas de apoyo (carpeta `salidas/`)

Cuando se necesita un desglose más fino que el de la entrega, la carpeta `salidas/` contiene tablas «largas» listas para tabla dinámica o `groupby`. Todas se cruzan por `identificacion` (salvo las de revistas, por `cod_rh/issn`):

Tabla	Llave	Desglose que aporta
<code>secop_regional</code>	<code>identificacion</code>	contratos y valor por departamento de ejecución
<code>secop_dims</code>	<code>identificacion</code>	por tipo de contrato, modalidad y nivel de la entidad
<code>secop_unspsc</code>	<code>identificacion</code>	por código UNSPSC del objeto contratado (SECOP II)
<code>rues_dims</code>	<code>identificacion</code>	por estado de matrícula, organización jurídica y CIU
<code>cvlac_issn</code>	<code>cod_rh → issn</code>	revista (ISSN) de cada artículo
<code>cvlac_issn_openalex</code>	<code>issn</code>	país, DOAJ, campo y dominio de cada revista

7. Tres advertencias para no equivocarse

- **La cédula es texto, no número.** Si Excel o pandas la leen como número, los documentos con ceros a la izquierda pierden dígitos y el cruce falla en silencio. Fuérzala a texto (`dtype=str` en pandas; formato *Texto* en Excel) *antes* de cruzar.
- **No sumes a través de granos distintos.** Si unes la maestra (una fila por persona) con una tabla larga (varias filas por persona, como `secop_regional`), la persona se duplica; suma o cuenta *después* de agrupar, nunca antes.
- **Las cifras de RUES y CvLAC son pisos.** El RUES solo capta a la persona natural (no las sociedades por NIT) y CvLAC es cobertura parcial validada por evidencia; léelas como mínimos, no como totales.

El diccionario columna por columna está en `diccionario_datos.csv`; los indicadores principales, en `resumen_indicadores.csv`; y la lectura analítica completa, en el informe de hallazgos. Datos de carácter personal: uso interno institucional sujeto a la política de tratamiento de datos de la Universidad.